

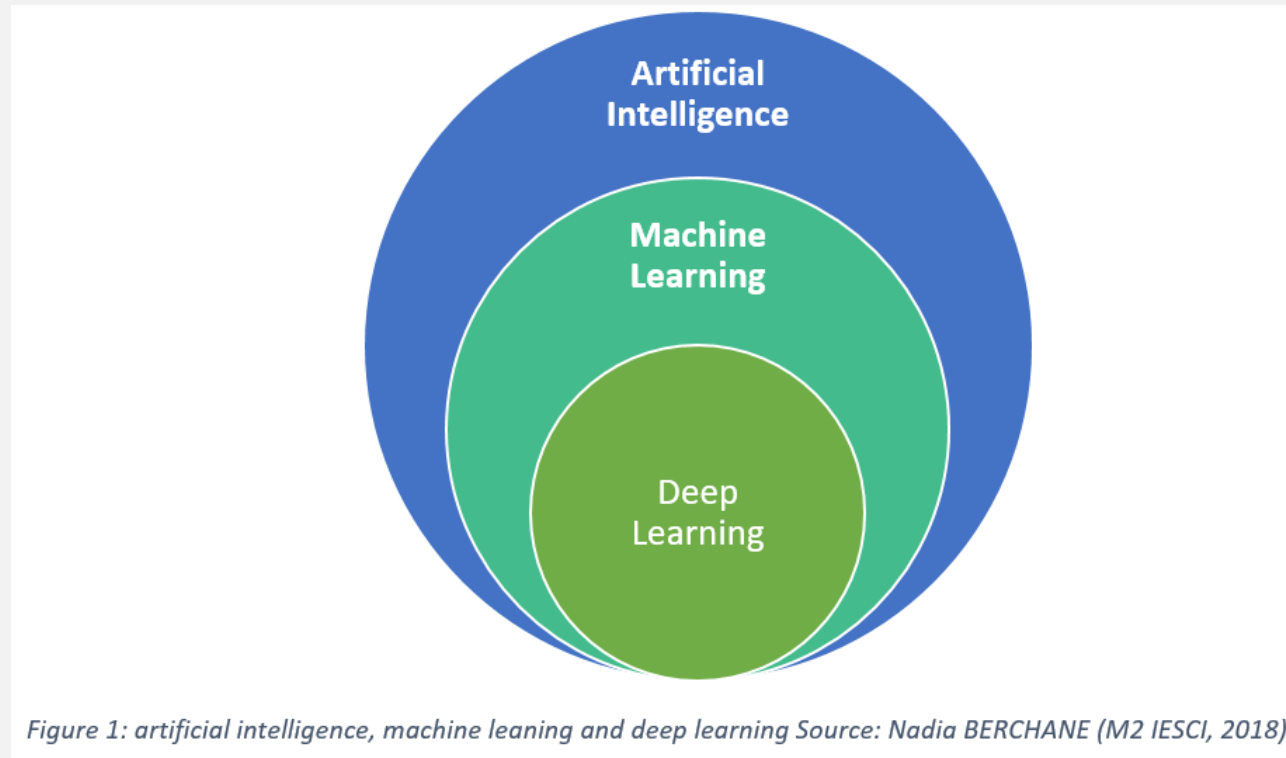
머신러닝 machine learning (ML)

머신러닝의 정의와 용어

알파고? 딥러닝? 머신러닝? 인공지능?



머신러닝의 정의와 용어



인공지능: 사람의 지능을 모방하여, 사람이 하는 것과 같이 복잡한 일을 할 수 있게 기계를 만드는 것

머신러닝: 기본적으로 알고리즘을 이용해 데이터를 분석 및 학습하며, 학습한 내용을 기반으로 판단이나 예측

딥러닝: 인공신경망에서 발전한 형태의 인공 지능. 머신러닝 중 하나의 방법론

머신러닝의 정의와 용어

데이터를 기반으로 패턴을 학습하여 결과를 추론하는 것

Data

Model

Prediction

과거에는...

데이터를 기반으로 패턴을 학습하여 결과를 추론하는 것

Data

Model

Prediction



머신러닝

데이터를 기반으로 패턴을 학습하여 결과를 추론하는 것

Data

Model


Prediction



머신러닝


머신러닝의 학습 방법

데이터를 기반으로 패턴을 학습하여 결과를 추론하는 것



지도학습

입력 데이터



출력 데이터

“자동차”

“비행기”

머신러닝의 위한 기초 수학

수식

y 실제값

\hat{y} 예측값 (y hat)

\bar{y} 평균값 (y bar)

수식

$$y = f(x)$$

$$y = ax + b$$

$$f(x) = ax + b$$

합계 (Summation), 평균 (Mean)


$$\sum_{i=1}^n a_i = a_1 + a_2 + a_3 + \dots + a_{n-1} + a_n$$

$$\begin{aligned} \boxed{\frac{1}{n}} \sum_{i=1}^n a_i &= \boxed{\frac{1}{n}} (a_1 + a_2 + a_3 + \dots + a_{n-1} + a_n) \\ &= \frac{(a_1 + a_2 + a_3 + \dots + a_{n-1} + a_n)}{\boxed{n}} \end{aligned}$$

1차 함수

$$f(x) = ax + b$$

a: 기울기, b: 절편




1차 함수

$$y = \boxed{w}x + \boxed{b}$$

~~a: 기울기, b: 절편~~

w: 가중치(weight), b: 편향
(bias)



1차 함수


$$f(x) = wx + b$$



1차 함수


$$f(x) = wx + b$$

b가 변하면?




2차 함수

$$f(x) = x^2$$



미분 (derivative)

한 점에서의 기울기!



미분 (derivative)

$$y = 3$$

$$y' = 0$$

모든 상수의 미분은 “0”

$$y = 4x + 3$$

$$y' = 4$$

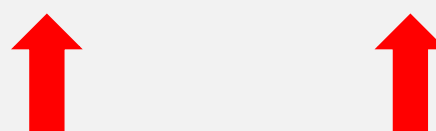
1차식의 미분은 “상수 값”

$$y = x^2$$

$$y' = 2x$$

편미분 (partial derivative)

변수가 **2개 이상**일 때의 미분?

$$y = 2a^2 + 3b + 6$$
Two red arrows pointing upwards from below the equation. One arrow points to the variable 'a' in the term '2a^2', and the other points to the variable 'b' in the term '3b'.

편미분 (partial derivative)

a에 대한 미분

$$\frac{\partial}{\partial a}y = \frac{\partial y}{\partial a} = \frac{\partial}{\partial a}(2a^2 + 3b + 6)$$

a를 제외한 나머지는 상수 취급

$$\frac{\partial y}{\partial a} = 4a$$

편미분 (partial derivative)

b에 대한 미분

$$\frac{\partial}{\partial b}y = \frac{\partial y}{\partial b} = \frac{\partial}{\partial b}(2a^2 + 3b + 6)$$

b를 제외한 나머지는 상수 취급

$$\frac{\partial y}{\partial b} = 3$$

합성함수의 미분

$$f(x) = ax^2 + b$$

$$g(x) = x^3$$

$$g(f(x)) = (ax^2 + b)^3$$

합성함수의 미분

$$g' = \frac{\partial g}{\partial x} = \frac{\partial}{\partial x} (ax^2 + b)^3$$

$$f(x) = A = ax^2 + b$$

$$g'(x) = \frac{\partial}{\partial x} (A^3)$$

$$= 3A^2 \cdot A'$$

$$= 3(ax^2 + b)^2 \cdot \frac{\partial}{\partial x} (ax^2 + b)$$

$$= 3(ax^2 + b)^2 \cdot (2ax)$$

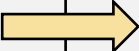
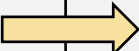
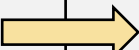
머신러닝의 원리

머신러닝의 원리

$y = wx + b$ 일때, 다음을 만족하는 w, b 는 무엇일까요?

$w = ?$

$b = ?$

x		y
1		3
2		5
3		7

가설함수 (hypothesis function)

- X, Y 데이터가 주어졌을 때, 해를 구할 수 있는 **잠정적인 수식**

$$h(x) = wx + b$$

x	y
1	3
2	5
3	7

가설함수 (hypothesis function)

Trial 1.

임의의 w , b 값을 대입

$$w = 0.5$$

$$b = 0.5$$

$$y = 0.5x + 0.5$$

x	y (actual)	\hat{y} (prediction)
1	3	1
2	5	1.5
3	7	2

가설함수 (hypothesis function)

Trial 2.

임의의 w , b 값을 대입

$$w = 1$$

$$b = 1$$

$$y = x + 1$$

x	y (actual)	\hat{y} (prediction)
1	3	2
2	5	3
3	7	4

가설함수 (hypothesis function)

Trial 3.

임의의 w , b 값을 대입

$$w = 2$$

$$b = 1$$

$$y = 2x + 1$$

x	y (actual)	\hat{y} (prediction)
1	3	3
2	5	5
3	7	7

가설함수 (hypothesis function)

No	Trial	x	y (actual)	\hat{y} (prediction)
1	$w = 0.5$ $b = 0.5$ $y = 0.5x + 0.5$	1	3	1
		2	5	1.5
		3	7	2
2	$w = 1$ $b = 1$ $y = x + 1$	1	3	2
		2	5	3
		3	7	4
3	$w = 2$ $b = 1$ $y = 2x + 1$	1	3	3
		2	5	5
		3	7	7

Error(오차) / Loss(손실)

No	Trial	x	y (actual)	\hat{y} (prediction)	Error ($y - \hat{y}$)
1	$w = 0.5$ $b = 0.5$ $y = 0.5x + 0.5$	1	3	1	2
		2	5	1.5	3.5
		3	7	2	5
2	$w = 1$ $b = 1$ $y = x + 1$	1	3	2	1
		2	5	3	2
		3	7	4	3
3	$w = 2$ $b = 1$ $y = 2x + 1$	1	3	3	0
		2	5	5	0
		3	7	7	0

(참고)

Loss (손실) = Error (오차)

머신러닝/딥러닝 에서는
Error (오차)를
Loss 혹은 **Cost** 라고
정의 합니다.

오차의 합 (Sum of Errors)

No	Trial	x	y (actual)	\hat{y} (prediction)	Error ($y - \hat{y}$)	Sum of Errors $\Sigma(y - \hat{y})$
1	$w = 0.5$ $b = 0.5$ $y = 0.5x + 0.5$	1	3	1	2	$2 + 3.5 + 5$ $= 10.5$
		2	5	1.5	3.5	
		3	7	2	5	
2	$w = 1$ $b = 1$ $y = x + 1$	1	3	2	1	$1 + 2 + 3$ $= 6$
		2	5	3	2	
		3	7	4	3	
3	$w = 2$ $b = 1$ $y = 2x + 1$	1	3	3	0	$0 + 0 + 0$ $= 0$
		2	5	5	0	
		3	7	7	0	

오차의 합 (Sum of Errors)

No	Sum of Errors $\Sigma(y - \hat{y})$
1	$2 + 3.5 + 5$ $= 10.5$
2	$1 + 2 + 3$ $= 6$
3	$0 + 0 + 0$ $= 0$

$$\Sigma(y - \hat{y}) = 0$$

을 만족하는 w, b 를 구하는 것

오차의 합 (Sum of Errors)

$$\Sigma(y - \hat{y}) = 0$$

을 만족하는 w, b 를 구하는 것


오차는 $y - \hat{y}$ 의 결과로 구해지므로
“양수”나 “음수”가 나올 수 있다.

오차가 “양수”와 “음수”로 이루어져 있다면
오차의 총합은

(예시)

$$2 + (-2) + (-1) + 3 + (-2) + 1 + (-1) = “0”$$

산술적인 오차의 합이 = “0” 되는 현상이 발생한다.



오차의 합 (Sum of Errors)

오차 $(y - \hat{y})$ 에 **제곱**을 씌워 음수 값이 나올 수 없게 만든다

$$\boxed{\Sigma(y - \hat{y})} \quad \Rightarrow \quad \boxed{\Sigma(y - \hat{y})^2}$$

제곱 과 **합**(Σ) 을 하면 굉장히 **큰 수**가 나올 수 있어
n개로 나누어 **평균**으로 만든다



$$\boxed{\frac{1}{n} \Sigma(y - \hat{y})^2}$$

평균 제곱 오차 (Mean Squared Error)

- 평균 제곱 오차 (MSE)
 - 오차에 제곱을 취한 평균을 취한 수식

$$\frac{1}{n} \sum (y - \hat{y})^2$$

평균 제곱 오차 (Mean Squared Error)

$$\frac{1}{n} \sum (y - \hat{y})^2 \approx 0$$

결국, MSE를 “0”에 가깝게 만드는 w, b 를 구해야 합니다.


< MSE를 “0”에 가깝게 만드는 w, b 를 구하는 법 >

MSE를 w 와 b 에 대하여 각각 편미분하여 w 와 b 값을 업데이트 해주는
“**경사하강법**” 을 알아보도록 하겠습니다.


경사하강법 (Gradient Descent)

경사 하강법

경사를 타고 내려와
최저점 (Loss가 가장 낮은 지점) 에 도달하는 최적화 알고리즘



경사하강법 (Gradient Descent)




$$w = w - w'$$

W (기울기)를 감소하면서
최저점에 도달할 때까지
기울기를 업데이트

학습률 (Learning Rate)


learning_rate

Low Learning Rate




학습률이 너무 작은 경우
= **학습이 진행 X**

Decent learning Rate



High Learning Rate



학습률이 너무 큰 경우
= **minimum 도달 X**

경사하강법 (Gradient Descent)

$$w = w - \alpha \cdot w'$$

$$= w - \alpha \cdot \frac{\partial}{\partial w}(Loss) \quad \longrightarrow \quad Loss = \frac{1}{n} \sum (\hat{y} - y)^2$$

$$= w - \alpha \cdot \frac{\partial}{\partial w} \left(\frac{1}{n} \sum (\hat{y} - y)^2 \right)$$

경사하강법 (Gradient Descent) 수식 유도

경사하강법 (Gradient Descent)

$$w = w - \alpha \cdot \frac{1}{n} \sum (\hat{y} - y) \cdot x$$

$$b = b - \alpha \cdot \frac{1}{n} \sum (\hat{y} - y)$$